

НАИВНЫЙ БАЙЕСОВСКИЙ КЛАССИФИКАТОР

Выполнил:
Скопинцев Никита,
25222 группа

Теорема Байеса

Теорема Байеса - это простая математическая формула, используемая для расчета условных вероятностей.

Условная вероятность - это мера вероятности того, что событие произойдет, учитывая, что другое событие (по предположению, допущению, утверждению или доказательству) произошло.


Проще говоря, теорема Байеса - это способ нахождения вероятности, когда нам известны некоторые другие вероятности.

Наивный байесовский алгоритм - это алгоритм классификации, основанный на теореме Байеса с допущением о независимости признаков.

Наивный байесовский классификатор (Naive Bayes classifier) — вероятностный классификатор на основе формулы Байеса со строгим (наивным) предположением о независимости признаков между собой при заданном классе, что сильно упрощает задачу классификации из-за оценки одномерных вероятностных плотностей вместо одной многомерной.

Формула

как часто случается А, учитывая, что случается В, записывается $P(A|B)$, также называемая апостериорной вероятностью, Когда мы знаем: как часто случается В, учитывая, что случается А, записывается $P(B|A)$ и насколько вероятно А само по себе, записывается $P(A)$ и насколько вероятно В само по себе, записывается $P(B)$.



The diagram shows the formula for Bayes' theorem with four annotations and arrows pointing to the corresponding parts of the equation:

- Probability of B occurring given evidence A has already occurred** points to $P(B|A)$.
- Probability of A occurring** points to $P(A)$.
- Probability of A occurring given evidence B has already occurred** points to $P(A|B)$.
- Probability of B occurring** points to $P(B)$.

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Как работает наивный байесовский алгоритм?

Пусть у нас есть набор данных, содержащий один признак «Погодные условия» (weather) и целевую переменную «Игра» (play), которая обозначает возможность проведения матча. На основе погодных условий мы должны определить (предсказать), состоится ли матч.

1. Пусть у нас есть набор наблюдений

	A	B
1	weather	play
2	sunny	no
3	overcast	yes
4	rainy	yes
5	sunny	yes
6	sunny	yes
7	overcast	yes
8	rainy	no
9	rainy	no
10	sunny	yes
11	rainy	yes
12	sunny	no
13	overcast	yes
14	overcast	yes
15	rainy	no

2. Преобразуем набор данных в частотную таблицу (frequency table)

A	B	C
weather	no	yes
overcast	0	4
rainy	3	2
sunny	2	3
total	5	9

3. Преобразуем частоты в таблицу правдоподобия, рассчитав соответствующие вероятности

Likelihood table				
Weather	No	Yes		
Overcast		4	$=4/14$	0.29
Rainy	3	2	$=5/14$	0.36
Sunny	2	3	$=5/14$	0.36
All	5	9		
	$=5/14$	$=9/14$		
	0.36	0.64		

Например,
вероятность
облачной погоды
составляет 0.29, а
вероятность того, что
матч состоится 0.64

Задача: какова вероятность проведения матча в зависимости от погоды.

Решение: X – это Да или Нет (то есть у нас два класса).

C – типы погоды (overcast, sunny, rainy) - признаки

Вероятность проведения матча в солнечную погоду.

С помощью теоремы Байеса рассчитаем апостериорную вероятность для каждого класса при данных погодных условиях. Класс с наибольшей апостериорной вероятностью будет результатом прогноза.

$$P(\text{yes/sunny}) = \frac{P(\text{sunny/yes}) * P(\text{yes})}{P(\text{sunny})}$$

$$P(\text{sunny/yes}) = 3/9$$

$$P(\text{yes}) = 9/14$$

$$P(\text{sunny}) = 5/14$$

$$P(\text{yes/sunn}) = \frac{\left(\frac{3}{9}\right) * \left(\frac{9}{14}\right)}{P\left(\frac{5}{14}\right)} = 0.6$$

$$P(\text{no/sunn}) = \frac{\left(\frac{2}{5}\right) * \left(\frac{5}{14}\right)}{P\left(\frac{5}{14}\right)} = 0.4$$

$$P(\text{no/sunny}) = \frac{P(\text{sunny/no}) * P(\text{no})}{P(\text{sunny})}$$

$$P(\text{sunny/no}) = 2/5$$

$$P(\text{sunny}) = 5/14$$

$$P(\text{no}) = 5/14$$

Плюсы и минусы наивного байесовского алгоритма

Положительные стороны:

1. Классификация, в том числе многоклассовая, выполняется легко и быстро.
2. НБА лучше работает с категориальными признаками, чем с непрерывными.

Отрицательные стороны:

1. Если в тестовом наборе данных присутствует некоторое значение категориального признака, которое не встречалось в обучающем наборе данных, тогда модель присвоит нулевую вероятность этому значению и не сможет сделать прогноз. Это явление известно под названием «нулевая частота».
2. Еще одним ограничением НБА является допущение о независимости признаков. В реальности наборы полностью независимых признаков встречаются крайне редко.

Области применения

1. **Классификация в режиме реального времени.** НБА очень быстро обучается, поэтому его можно использовать для обработки данных в режиме реального времени (котировки акций).
2. **Многоклассовая классификация.** НБА обеспечивает возможность многоклассовой классификации.
3. **Классификация текстов, фильтрация спама, анализ тональности текста.** При решении задач, связанных с классификацией текстов, НБА превосходит многие другие алгоритмы. Благодаря этому, данный алгоритм находит широкое применение в области фильтрации спама (идентификация спама в электронных письмах) и анализа тональности текста (анализ социальных медиа, идентификация позитивных и негативных мнений клиентов).

Разновидности наивного Байеса

В библиотеке **scikit-learn** есть несколько реализаций наивного байесовского классификатора, отличающиеся предположениями о распределении признаков при заданном классе. К таковым относятся следующие:

- **Гауссовский наивный байесовский классификатор (GaussianNB)** — вариант для работы с непрерывными признаками, которые имеют нормальное (гауссовское) распределение.
- **Мультиномиальный наивный байесовский классификатор (MultinomialNB)** — вариант для работы с дискретными признаками, которые имеют мультиномиальное распределение. Такие признаки часто встречаются в задачах классификации текстов, где они представляют собой количество вхождений в тексте.

Разновидности наивного Байеса

- **Комплементарный наивный байесовский классификатор (ComplementNB)** — улучшенный вариант MultinomialNB, подходящий для несбалансированных наборов данных. Вместо оценки вероятности признака при заданном классе, алгоритм оценивает нормированный вес признака $w_{\{c_i\}}$ для класса c как вероятность признака при дополнении класса, то есть при всех остальных классах. Таким образом, алгоритм учитывает не только частоту признаков в классе, но и их отсутствие в других классах, что делает его менее чувствительным к смещению выборки.

Разновидности наивного Байеса

- **Бернуллиевский наивный байесовский классификатор (BernoulliNB)**
— ещё один вариант для работы с дискретными признаками, но которые имеют бернуллиевское распределение. В данном случае признаки представляют собой бинарные индикаторы наличия или отсутствия определённых свойств в объекте. Например, в задаче классификации текстов это может быть наличие или отсутствие определённых слов в тексте.

Разновидности наивного Байеса

- **Бернуллиевский наивный байесовский классификатор (BernoulliNB)** — ещё один вариант для работы с дискретными признаками, но которые имеют бернуллиевское распределение. В данном случае признаки представляют собой бинарные индикаторы наличия или отсутствия определённых свойств в объекте. Например, в задаче классификации текстов это может быть наличие или отсутствие определённых слов в тексте.
- **Категориальный наивный байесовский классификатор (CategoricalNB)** — вариант для категориально распределённых данных, основанный на предположении, что каждый описываемый индексом признак имеет своё собственное категориальное распределение.

Принцип работы наивного байесовского классификатора с гауссовским распределением

1. изначально рассчитываются априорные вероятности классов;
2. после рассчитываются средние и стандартные отклонения признаков по классам;
3. на основе полученных отклонений признаков по классам рассчитывается вероятностная плотность тестовых признаков по распределению Гаусса;
4. далее вычисляются апостериорные вероятности как произведение априорных вероятностей классов и вероятностных плотностей тестовых признаков;
5. классы с максимальной апостериорной вероятностью будут итоговым прогнозом.